Pythonによるデータ可視化

初めての人向け・90分×8コマ

Invalid Date

目次

1 第3コマ　データ集め、データ（変数）の尺度 **1**

1.1 データ集めの主な方法 1
1.2 「度量衡」という言葉について 1
1.3 変数と尺度：データには「ものさし」がある 2
1.4 尺度で「できること」が違う 2
1.4.1 数字でも、名義尺度として扱うもの 2
1.5 水準と選択肢 2
1.6 標本という考え方 2
1.7 尺度とグラフの相性（目安） 3
1.8 実習：データを読み込んで、列の尺度を考える 3
1.9 演習 4
1.10 まとめ 4

1 第3コマ　データ集め、データ（変数）の尺度

このコマの進め方：講義（45分） → 一緒に実習（30分） →演習と振り返り（15分）。

1.1 データ集めの主な方法

- **調査（アンケート）**：聞いて集める。質問の書き方で答えが変わる点に注意
- **観察・記録**：出来事をそのまま記録する。測り方をそろえることが大事
- **実験**：条件を変えて結果を比べる。比べる相手（対照）を用意する
- **既存データ**：公的な統計や、業務でたまったデータを使う。元の集め方を確認する

1.2 「度量衡」という言葉について

このコマで出てくる「度量衡（どりょうこう）」は、昔からの「測るための共通のものさし」のことです。

- 度（ど）＝長さ、量（りょう）＝かさ（体積）、衡（こう）＝重さ
- 今で言えば、メートル・リットル・グラムといった**単位の体系そのもの**
- この後の「比尺度」の正体は、この度量衡です。「誰がどこで測っても同じになる単位で測った数値」とつながります

1.3 変数と尺度：データには「ものさし」がある

- 変数とは、測ったり記録したりする項目のこと（身長、満足度、血液型、気温…）
- 尺度とは、その変数がどんな性質の「ものさし」で測られているか、という区別です
- 尺度が違うと、**やってよい計算や、合うグラフが変わります**

尺度	例	イメージ
名義尺度	血液型、商品名、天気	名札。区別だけ
順序尺度	順位、混雑具合、言葉の満足度（不満～満足）	順番はあるが間隔は不ぞろい
間隔尺度	気温（℃）、西暦、数値化した満足度	間隔は均等。0は「無」ではない
比尺度	身長、金額、個数	度量衡（長さ・重さなどの共通単位）。0＝本当に無い

1.4 尺度で「できること」が違う

尺度	数える・割合	順位	差を言う（較べる）	倍率を言う（比べる）	平均
名義	できる	できない	できない	できない	できない
順序	できる	できる	できない	できない	注意
間隔	できる	できる	できる	できない	できる
比	できる	できる	できる	できる	できる

- 差を言う場合（気温）：較べる。5 ℃差と5 ℃差は同じ
- 倍率を言う場合（重さ）：比べる。「2倍重い」が言える
- 間隔尺度では、倍率は言えません（20 ℃は10 ℃の「2倍暑い」ではない）
- 度量衡でない数値データ（満足度など感覚を数値化したもの）も、**間隔尺度として扱います**。満足度は平均も使いますが、「4点は2点の2倍満足」とは言えません

1.4.1 数字でも、名義尺度として扱うもの

- 背番号、郵便番号、商品コードのように、順序の意味（大小・強弱・優劣）がない数値は、**数字符号**として名義尺度扱いです

1.5 水準と選択肢

- **水準**：変数が取りうる値のこと。天気なら「晴れ・くもり・雨」が水準です
- **選択肢**：調査で答えてもらうために用意する水準の並び
- 選択肢の約束：もれがない（「その他」を用意）、重ならない、順序のあるものは順序を保つ
- 文字列の水準でも順序があれば順序尺度（例：順位、混雑具合、言葉の満足度）。数値に割り振り直せば、間隔尺度として扱ってよい

1.6 標本という考え方

- 本当に知りたい全体を**母集団**、実際に集めたデータを**標本（サンプル）**と言います
- 講座のデータも、たいていは標本です（例：来場者全員ではなく、協力してくれた80名）
- 結論はまず、「この標本では、こう見えた」と言える範囲に置くのが安全です
- 標本の偏り（若い人ばかり、協力的で元気な人ばかり等）があると、全体の姿とずれることがあります

1.7 尺度とグラフの相性(目安)

尺度	合うグラフ	例
名義	棒グラフ(人数・割合)	血液型ごとの人数
順序	棒グラフ(人数・割合)	満足度ごとの人数
間隔・比	ヒストグラム／箱ひげ図／折れ線／散布図	身長の分布、気温の変化

読み取りのポイント：**名義・順序は「人数を数えて棒グラフ」。平均の棒グラフにはしません。**間隔・比は分布を見るヒストグラムや箱ひげ図が使えます。

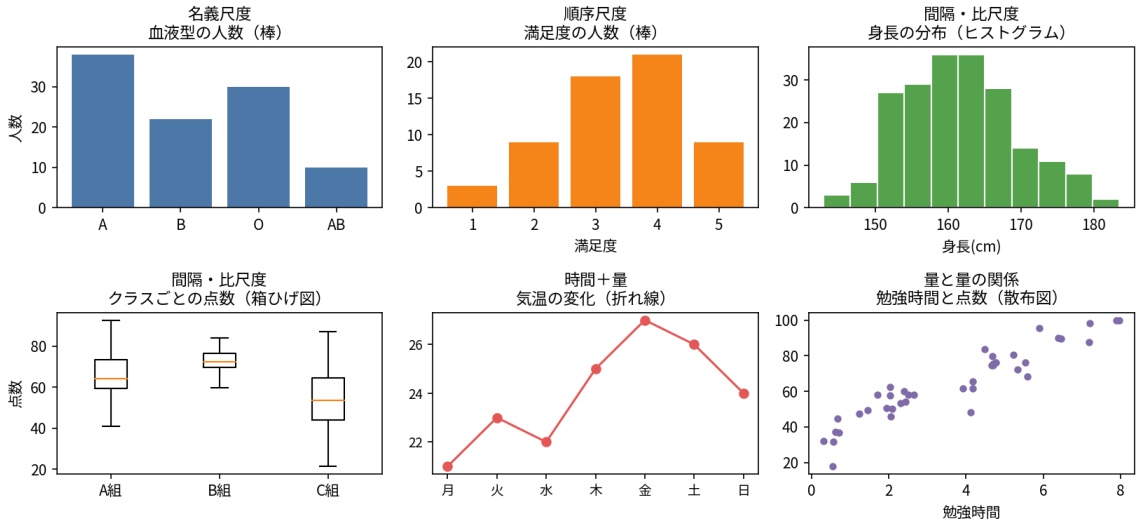


図 1: 尺度ごとの例となるグラフ

1.8 実習：データを読み込んで、列の尺度を考える

```
survey = pd.read_csv("data/survey.csv")
print(survey.head())
print(survey["年代"].unique())          # 水準を取り出す
print(survey["満足度"].value_counts())
```

```
    年代  満足度  来店回数
0  20代     5    16
1  10代     5    10
2  40代     1     3
3  30代     3     7
4  10代     2    18
<StringArray>
['20代', '10代', '40代', '30代', '50代', '60代以上']
Length: 6, dtype: str
満足度
5    14
```

```
4    14
1    12
3    10
2    10
Name: count, dtype: int64
```

列ごとに「これは何尺度か」を言えるようにしておきましょう。

1.9 演習

1. 身の回りのデータを3つ挙げ、それぞれの尺度を答える
2. 次のデータはどの尺度か：背番号、気温、血液型、満足度（1〜5点）、身長、順位
    - 背番号：名義（数字符号）。気温：間隔。満足度（数値）：間隔として扱う。順位：順序
3. アンケートの選択肢を1つ作り、「もれ・重なり・順序」の点検をする

1.10 まとめ

- 尺度は4つ（名義・順序・間隔・比）。比尺度の正体は度量衡
- 尺度によって、できる計算と合うグラフが決まる
- データは標本。結論は「この標本ではこう見えた」から始める