Pythonによるデータ可視化

初めての人向け・90分×8コマ

Invalid Date

目次

1 第4コマ　表のいろいろ・表作成 **1**

1.1 表の4段階 1
1.2 段階1：収集（一覧表） 1
1.3 段階2：要約（代表値・統計値の表） 2
1.4 段階3：関係（クロス集計表） 2
1.5 段階4：推測と混同行列 3
1.6 信号検出理論：刺激のあるなし × 反応のあるなし 3
1.7 表を作るときの約束 4
1.8 演習 4
1.9 まとめ（1日目の振り返り） 4

1 第4コマ　表のいろいろ・表作成

このコマの進め方：講義（40分） → 一緒に実習（35分） →演習と振り返り（15分）。表は「段階」ごとに姿が違います。収集 → 要約 →関係 → 推測、の4段階で整理します。

1.1 表の4段階

段階	表の姿	すること
1：収集	一覧表	集めたデータを、そのまま並べる
2：要約	変数ごとに代表値・統計値に置き換えた表	平均・中央値などの代表値や統計値で置き換える
3：関係	クロス集計表（分割表）	2つの変数の組み合わせで数える
4：推測	混同行列	推測の正誤の数を数える（行と列が同じカテゴリ）

1.2 段階1：収集（一覧表）

```
weather = pd.read_csv("data/weather_week.csv")
print(weather.head(10))
```

```
          日付 曜日  最高気温  最低気温  降水量
0  2026-11-09  月     21     13   0.0
1  2026-11-10  火     23     14   0.0
2  2026-11-11  水     22     15   3.5
3  2026-11-12  木     25     16   0.0
4  2026-11-13  金     27     17   0.0
5  2026-11-14  土     26     18  12.0
6  2026-11-15  日     24     15   0.5
```

- pandas では、表全体を **DataFrame** と呼びます
- まず全体を表示し、行数（データの件数）と列（変数）を確認します

```
print(weather.shape)      # (行数, 列数)
print(weather.dtypes)     # 各列の型
```

```
(7, 5)
日付      str
曜日      str
最高気温    int64
最低気温    int64
降水量    float64
dtype: object
```

1.3 段階2：要約（代表値・統計値の表）

一覧表のままでは姿が見えないので、変数ごとに代表値や統計値に置き換えます。

```
rt = pd.read_csv("data/psych_rt.csv")
print(rt[["反応時間", "正答数"]].describe())
```

```
          反応時間        正答数
count   80.000000  80.000000
mean   378.625000  16.150000
std     98.511115   2.038242
min    243.000000  11.000000
25%    327.750000  15.000000
50%    370.000000  16.000000
75%    400.250000  18.000000
max    837.000000  20.000000
```

- `describe()` は、個数・平均・標準偏差・最小・四分位数・最大を一度に並べてくれます
- ここの四分位数（25%、50%、75%）が、第5コマの箱ひげ図につながります

1.4 段階3：関係（クロス集計表）

```
survey = pd.read_csv("data/survey.csv")
print(pd.crosstab(survey["年代"], survey["満足度"]))
```

```
満足度   1  2  3  4  5
年代
10代    3  3  1  0  8
```

```
20代     2  2  3  3  1
30代     2  0  1  4  0
40代     2  2  3  2  2
50代     1  3  1  4  2
60代以上  2  0  1  1  1
```

- 割合で見たいときは `normalize="index"` を付けます（行ごとに100%）

```
ct = pd.crosstab(survey["年代"], survey["満足度"], normalize="index")
print((ct * 100).round(1))
```

```
満足度        1     2     3     4     5
年代
10代     20.0  20.0   6.7   0.0  53.3
20代     18.2  18.2  27.3  27.3   9.1
30代     28.6   0.0  14.3  57.1   0.0
40代     18.2  18.2  27.3  18.2  18.2
50代      9.1  27.3   9.1  36.4  18.2
60代以上   40.0   0.0  20.0  20.0  20.0
```

- グループごとの合計や平均は `groupby` で作ります（この例は「一元表」にもなります）

```
sales = pd.read_csv("data/shop_sales.csv")
sales["金額"] = sales["単価"] * sales["個数"]
by_item = (sales.groupby("商品")[["金額", "個数"]].sum()
           .rename(columns={"金額": "金額合計", "個数": "個数合計"})
           .sort_values("金額合計", ascending=False))
print(by_item)
```

```
        金額合計  個数合計
商品
コーヒー   541800  1204
紅茶     292400   731
ジュース   193200   552
ケーキ    189750   345
```

1.5 段階4：推測と混同行列

- 推測とは、あるデータの値から別のデータの値を当てることです。当てた結果の正しさを数えるのが、この段階の仕事です
- 推測の出来を評価する表が**混同行列**です。クロス集計表に似ていますが、**行と列が同じカテゴリ**（実際× 判断）なのが特徴で、斜めのマスが正解です
- 心理学の**信号検出理論**が、その代表例です（次へ）

1.6 信号検出理論：刺激のあるなし × 反応のあるなし

かすかな音が「聞こえたか」を答える実験のように、刺激があるかないかと、反応（「あった」と答えたか）の組み合わせで、判断の様子を調べる理論です。

実際 ＼ 反応	「あった」	「なかった」
刺激あり（50試行）	38 **ヒット**	12 **見落とし**
刺激なし（50試行）	9 **誤警報**	41 **正棄却**

- この人の的中の様子：刺激ありでは76%当て、刺激なしでは18%「あった」と言ってしまう
- 判断の基準がゆるい人は「ヒットも誤警報も多い」、厳しい人は「見落としが多い」といった具合に、4つのマスのバランスに、その人の判断のクセが表れます
- この表はまさに混同行列です。pandas では `pd.crosstab(刺激の列, 反応の列)` で作れます

```
sdt = pd.read_csv("data/sdt_trials.csv")
cm = pd.crosstab(sdt["刺激"], sdt["反応"])
print(cm)
hit_rate = cm.loc["あり", "あった"] / cm.loc["あり"].sum()
fa_rate = cm.loc["なし", "あった"] / cm.loc["なし"].sum()
print(f"ヒット率: {hit_rate:.0%} / 誤警報率: {fa_rate:.0%}")
```

```
反応　あった　なかった
刺激
あり　　38　　12
なし　　 9　　41
ヒット率: 76% / 誤警報率: 18%
```

1.7 表を作るときの約束

- タイトルと単位を付ける。「何の表か」が一目で分かること
- 数値の桁をそろえる。小数点以下の桁数は列ごとに統一する
- 出典と件数（n＝何件か）を添える

1.8 演習

1. survey.csv で、年代ごとの満足度クロス集計を「割合」の表にし、一文で読み取る
2. shop_sales.csv で、商品ごとの金額合計の一元表を作る（単価×個数＝金額の列を足してから合計）
3. sdt_trials.csv の混同行列から、ヒット率と誤警報率を求める

1.9 まとめ（1日目の振り返り）

- 表は4段階：収集（一覧表）／要約（代表値の表）／関係（クロス集計）／推測（混同行列）
- pandas では read_csv → head/shape → describe/crosstab/groupby が基本の流れ
- 明日は、この表をグラフに変えていきます