Pythonによるデータ可視化

初めての人向け・**90**分×**8**コマ

長崎大学 病院医療情報部 薗田 光太郎 (Kotaro Sonoda)

目次

講師用資料について 3

第1コマ 解答例 4

第2コマ 解答例 5

第3コマ 解答例 6

第4コマ 解答例 7

第5コマ 解答例 8

第6コマ 解答例 11

第7コマ 解答例（計画シート記入例） 13

第8コマ テスト模範解答 14

第8コマ テスト実施ガイド（講師用） 17

課題 17

データに埋め込まれたパターン（採点の目安。受験者はこのうち1つを深める） 17

評価の観点（目安：各5点、計20点） 17

実施上の注意 17

講師用資料について

この資料は講師用です。受講者向けの本(プロジェクト直下のbook)には含まれていません。

- 各コマの演習の解答例(第1〜8コマ)
- 第8コマテストの模範解答と、テスト実施ガイド(埋め込みパターンと評価基準)

元のファイルは、スライド版プロジェクト `lecture-dataviz/code/answers/` の .py と `test_guide.md` です。内容を更新するときは元のファイルを直し、このフォルダの .qmd に反映してください(data フォルダへのパスだけ、配置に合わせて調整しています)。

第1コマ 解答例

講師用の解答例です。元のファイルは `lecture-dataviz/code/answers/session1_answers.py` です（data フォルダへのパスだけ、この本の配置に合わせて調整しています）。

```
# 第1コマ 演習の解答例(口頭・ワークの例)
# データ1は「平均65点」で姿の大事なところ(真ん中に集まる)は伝わる。
# データ2は2つの山に分かれていること、データ3は満点の混入が
# 平均だけでは伝わらない。
# 言い換え例:
#   データ1:「多くの人が60〜70点に集まっている」
#   データ2:「50点前後と80点前後に分かれている」
#   データ3:「多くは60点前後だが、満点が数人混ざっている」
print("解答はスライドと口頭で確認します(このファイルはメモです)")
```

```
解答はスライドと口頭で確認します(このファイルはメモです)
```

第2コマ 解答例

講師用の解答例です。元のファイルは `lecture-dataviz/code/answers/session2_answers.py` です（data フォルダへのパスだけ、この本の配置に合わせて調整しています）。

```
# 第2コマ 演習の解答例

# 1. 平均
scores = [80, 90, 70, 100]
print(sum(scores) / len(scores))  # 85.0

# 2. 辞書で1行
item = {"商品": "紅茶", "単価": 400, "個数": 3}
print(item["商品"], item["単価"] * item["個数"])  # 紅茶 1200

# 3. 1から5までの2倍
for n in [1, 2, 3, 4, 5]:
    print(n * 2)
```

```
85.0
紅茶 1200
2
4
6
8
10
```

第3コマ 解答例

講師用の解答例です。元のファイルは `lecture-dataviz/code/answers/session3_answers.py` です（data フォルダへのパスだけ、この本の配置に合わせて調整しています）。

```
# 第3コマ 演習の解答例(尺度の判定)
answers = [
    ("郵便番号", "名義尺度", "平均NG(ただの番号)"),
    ("好きな色", "名義尺度", "平均NG(数えられるのは人数)"),
    ("テストの点数", "間隔尺度(比尺度と扱うことも多い)", "平均OK"),
    ("兄弟の人数", "比尺度", "平均OK"),
    ("駅の混雑具合", "順序尺度", "平均は参考程度、中央値や度数が向く"),
]
for name, scale, note in answers:
    print(f"{name}: {scale} / {note}")
```

郵便番号: 名義尺度 / 平均NG(ただの番号)
好きな色: 名義尺度 / 平均NG(数えられるのは人数)
テストの点数: 間隔尺度(比尺度と扱うことも多い) / 平均OK
兄弟の人数: 比尺度 / 平均OK
駅の混雑具合: 順序尺度 / 平均は参考程度、中央値や度数が向く

第4コマ 解答例

講師用の解答例です。元のファイルは lecture-dataviz/code/answers/session4_answers.py です（data フォルダへのパスだけ、この本の配置に合わせて調整しています）。

```python
# 第4コマ 演習の解答例(pandas)
from pathlib import Path

import pandas as pd

BASE = Path.cwd().parent  # この本では teacher フォルダの1つ上がプロジェクト直下

df = pd.read_csv(BASE / "data" / "weather_week.csv")
# 1. 最低気温の平均 / 降水量が0より大きい日
print("最低気温の平均:", df["最低気温"].mean())
print(df[df["降水量"] > 0])

# 2. 商品ごとの個数合計の一元表
sales = pd.read_csv(BASE / "data" / "shop_sales.csv")
by_qty = (sales.groupby("商品")["個数"].sum()
          .sort_values(ascending=False))
print(by_qty)

# 3. survey.csv で年代×満足度のクロス集計(人数)と気づき(例):
#「満足度5は若い年代に多い」のように、行と列の交わりを見て1つ書けばよい。
survey = pd.read_csv(BASE / "data" / "survey.csv")
print(pd.crosstab(survey["年代"], survey["満足度"]))
```

```
最低気温の平均: 15.428571428571429
          日付 曜日  最高気温  最低気温  降水量
2  2026-11-11  水    22    15   3.5
5  2026-11-14  土    26    18  12.0
6  2026-11-15  日    24    15   0.5
商品
コーヒー    1204
紅茶       731
ジュース     552
ケーキ      345
Name: 個数, dtype: int64
満足度    1  2  3  4  5
年代
10代     3  3  1  0  8
20代     2  2  3  3  1
30代     2  0  1  4  0
40代     2  2  3  2  2
50代     1  3  1  4  2
60代以上  2  0  1  1  1
```

第5コマ 解答例

講師用の解答例です。元のファイルは `lecture-dataviz/code/answers/session5_answers.py` です（data フォルダへのパスだけ、この本の配置に合わせて調整しています）。

```
# 第5コマ 演習の解答例(pandasでグラフ作成)
from pathlib import Path

import matplotlib.pyplot as plt
import numpy as np
import pandas as pd

# 日本語表示(matplotlib-fontja が使えない環境では、入っている日本語フォントを探す)
import matplotlib
try:
    import matplotlib_fontja  # noqa: F401
except Exception:
    from matplotlib import font_manager
    _fonts = {f.name for f in font_manager.fontManager.ttflist}
    for _n in ["IPAexGothic", "Noto Sans CJK JP", "Noto Sans JP",
               "Yu Gothic", "Meiryo", "Hiragino Sans"]:
        if _n in _fonts:
            matplotlib.rcParams["font.family"] = _n
            break
matplotlib.rcParams["axes.unicode_minus"] = False

BASE = Path.cwd().parent  # この本では teacher フォルダの1つ上がプロジェクト直下

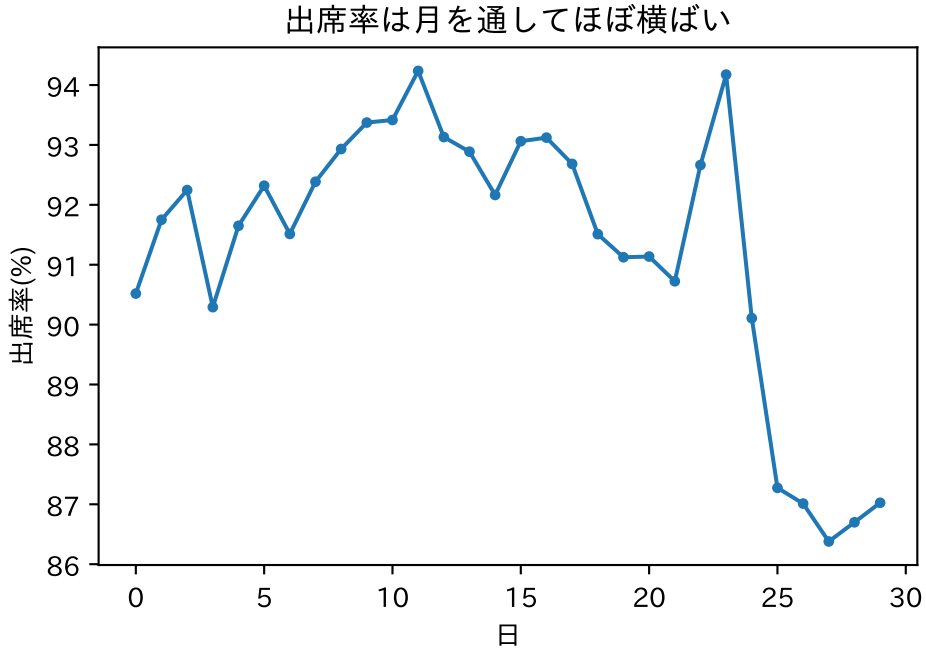
# 1a. 出席率の変化 → 折れ線
rate = pd.Series(np.clip(90 + np.cumsum(np.random.default_rng(1).normal(0, 1.5, 30)), 70, 100))
rate.plot.line(marker="o", markersize=3, title="出席率は月を通してほぼ横ばい",
               xlabel="日", ylabel="出席率(%)")
plt.show()

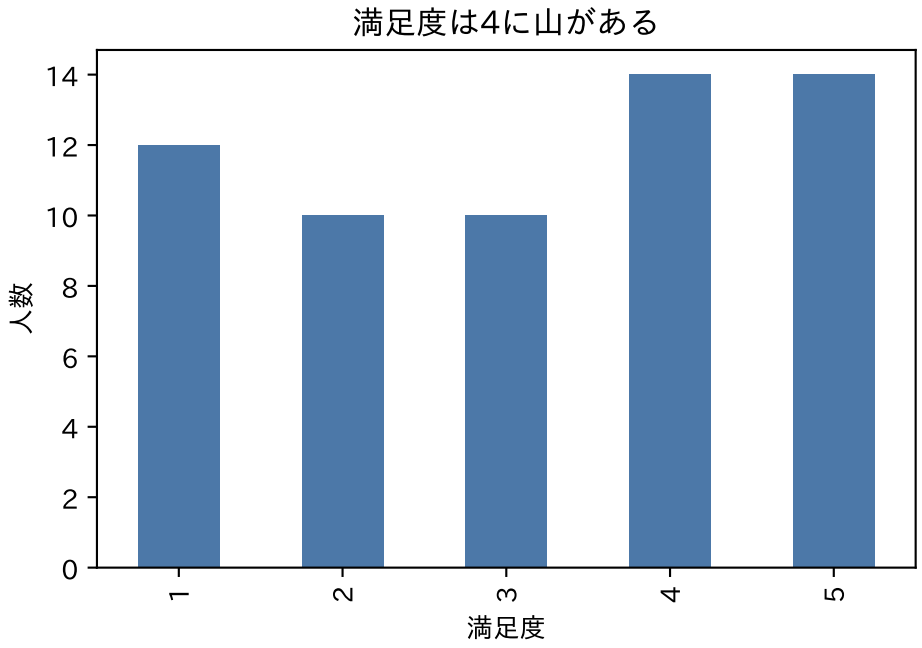
# 1b. 満足度の偏り → 度数の棒グラフ
survey = pd.read_csv(BASE / "data" / "survey.csv")
counts = survey["満足度"].value_counts().sort_index()
counts.plot.bar(color="#4C78A8", title="満足度は4に山がある",
                xlabel="満足度", ylabel="人数")
plt.show()

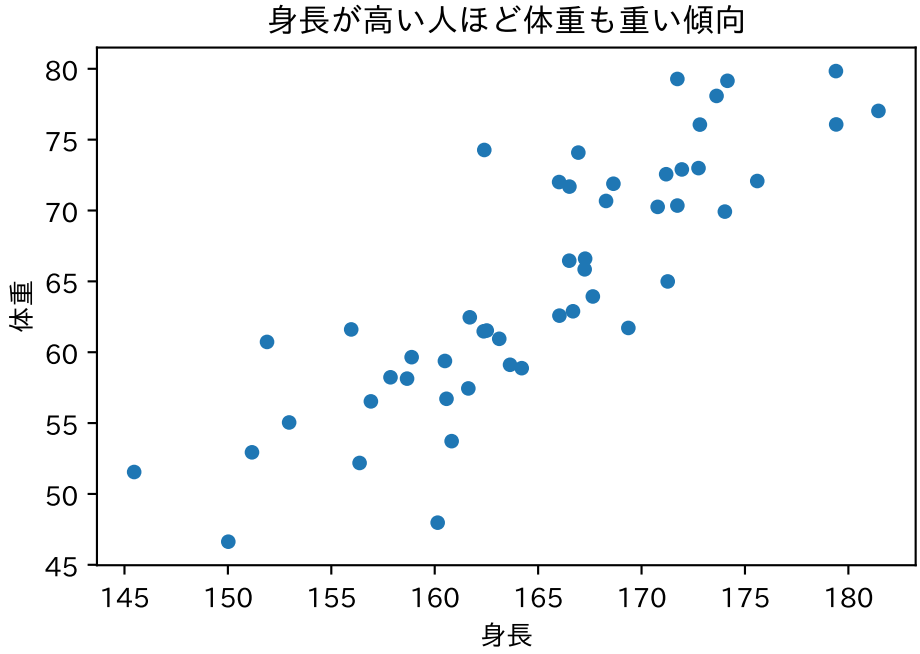
# 1c. 身長と体重の関係 → 散布図
rng = np.random.default_rng(2)
body = pd.DataFrame({"身長": rng.normal(165, 8, 50)})
body["体重"] = (body["身長"] - 100) + rng.normal(0, 5, 50)
body.plot.scatter(x="身長", y="体重", title="身長が高い人ほど体重も重い傾向")
```

```
plt.show()

# 2-3. 軸は0から、タイトルは結論形に(本文の例6がその形になっています)
```






身長が高い人ほど体重も重い傾向
体重
身長
80
75
70
65
60
55
50
45
145
150
155
160
165
170
175
180

第6コマ 解答例

講師用の解答例です。元のファイルは `lecture-dataviz/code/answers/session6_answers.py` です（data フォルダへのパスだけ、この本の配置に合わせて調整しています）。

```
# 第6コマ 演習の解答例(講師用デモ: 年代と反応時間 / 外れ値)
from pathlib import Path

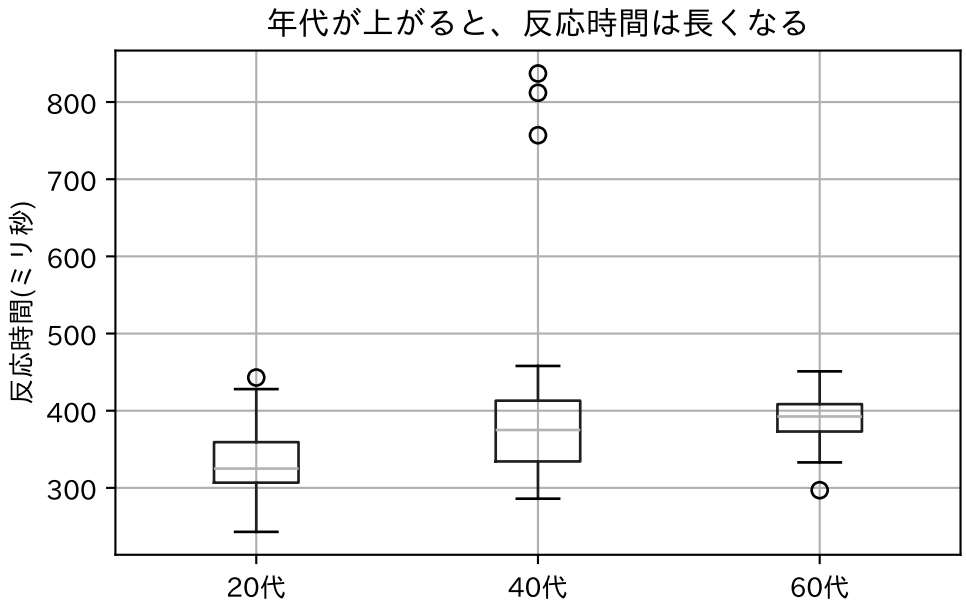
import matplotlib.pyplot as plt
import pandas as pd

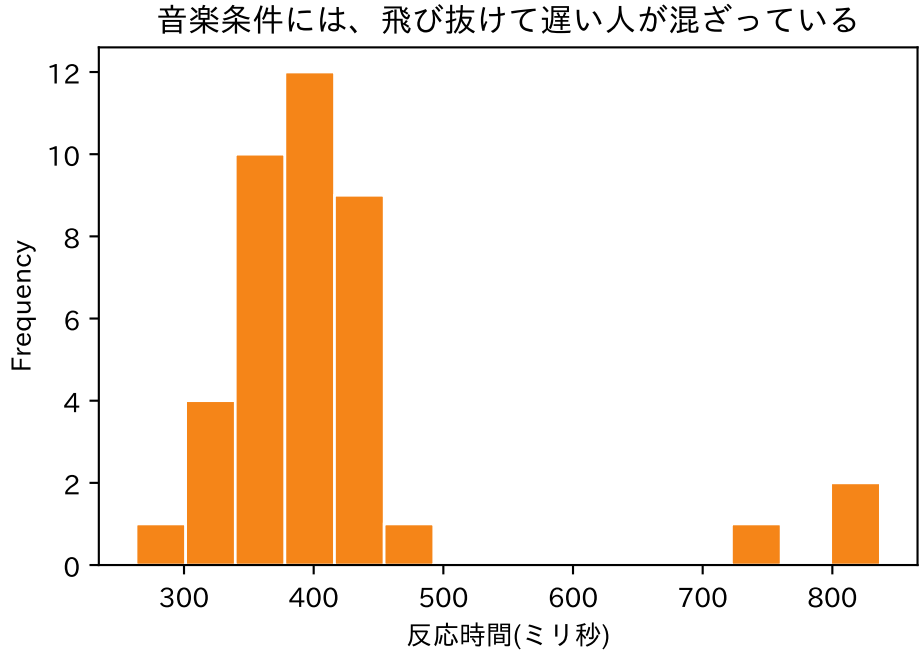
# 日本語表示(matplotlib-fontja が使えない環境では、入っている日本語フォントを探す)
import matplotlib
try:
    import matplotlib_fontja  # noqa: F401
except Exception:
    from matplotlib import font_manager
    _fonts = {f.name for f in font_manager.fontManager.ttflist}
    for _n in ["IPAexGothic", "Noto Sans CJK JP", "Noto Sans JP",
               "Yu Gothic", "Meiryo", "Hiragino Sans"]:
        if _n in _fonts:
            matplotlib.rcParams["font.family"] = _n
            break
    else:
        print("注意: 日本語フォントが見つかりません(グラフの日本語が四角になります)")
matplotlib.rcParams["axes.unicode_minus"] = False

BASE = Path.cwd().parent  # この本では teacher フォルダの1つ上がプロジェクト直下
rt = pd.read_csv(BASE / "data" / "psych_rt.csv")

# 気づき1: 年代が上がると反応時間が長い → 箱ひげ図で分布ごと比べる
rt.boxplot(column="反応時間", by="年代")
plt.title("年代が上がると、反応時間は長くなる")
plt.suptitle("")
plt.xlabel("")
plt.ylabel("反応時間(ミリ秒)")
plt.show()

# 気づき2: 音楽条件には飛び抜けて遅い人がいる → ヒストグラムで姿を見る
music = rt[rt["条件"] == "音楽あり"]
music["反応時間"].plot.hist(bins=15, color="#F58518", edgecolor="white",
                            title="音楽条件には、飛び抜けて遅い人が混ざっている",
                            xlabel="反応時間(ミリ秒)")
plt.show()
print("700ミリ秒以上:", len(music[music["反応時間"] >= 700]), "名")
```


年代が上がると、反応時間は長くなる
反応時間(ミリ秒)
800
700
600
500
400
300
20代
40代
60代


音楽条件には、飛び抜けて遅い人が混ざっている
Frequency
12
10
8
6
4
2
0
300
400
500
600
700
800
反応時間(ミリ秒)

700ミリ秒以上：3 名

第7コマ解答例（計画シート記入例）

講師用の解答例です。元のファイルは `lecture-dataviz/code/answers/session7_answers.py` です（data フォルダへのパスだけ、この本の配置に合わせて調整しています）。

```
# 第7コマ 実習の記入例（講師用）
plan_example = {
    "仮説": "課題の前に手本を見せると、正答数が増えるはず",
    "比べる相手": "手本を見せない条件の正答数",
    "必要な変数": ["手本の有無（名義）", "正答数（比尺度）", "反応時間（比尺度）", "年代（名義）"],
    "集め方": "実験：参加者を2つの条件に分け、同じ課題を実施する",
    "相手と数": "各条件30名ずつ（計60名）",
    "期間": "来週の月曜〜金曜",
    "偏りへの対策": "条件ごとに年代や性別が偏らないよう割り付ける。実施する時間帯もそろえる",
}
for k, v in plan_example.items():
    print(k, ":", v)
```

仮説 ： 課題の前に手本を見せると、正答数が増えるはず
比べる相手 ： 手本を見せない条件の正答数
必要な変数 ： ['手本の有無（名義）', '正答数（比尺度）', '反応時間（比尺度）', '年代（名義）']
集め方 ： 実験：参加者を2つの条件に分け、同じ課題を実施する
相手と数 ： 各条件30名ずつ（計60名）
期間 ： 来週の月曜〜金曜
偏りへの対策 ： 条件ごとに年代や性別が偏らないよう割り付ける。実施する時間帯もそろえる

第8コマテスト模範解答

講師用の解答例です。元のファイルは lecture-dataviz/code/answers/session8_answers.py です（data フォルダへのパスだけ、この本の配置に合わせて調整しています）。

```
# 第8コマ テストの模範解答(講師用)
# 受験者は気づきを1つに絞る。ここには候補となる作例を載せる。
# 埋め込まれたパターン:
#  1. 年代が上がると反応時間が長い
#  2. ペア条件は速いが、ばらつきが大きい
#  3. 午後は午前より反応時間が長い
#  おまけ: 外れ値2名(980, 1050) / 反応時間の欠けた値2件
from pathlib import Path

import matplotlib.pyplot as plt
import pandas as pd

# 日本語表示(matplotlib-fontja が使えない環境では、入っている日本語フォントを探す)
import matplotlib
try:
    import matplotlib_fontja  # noqa: F401
except Exception:
    from matplotlib import font_manager
    _fonts = {f.name for f in font_manager.fontManager.ttflist}
    for _n in ["IPAexGothic", "Noto Sans CJK JP", "Noto Sans JP",
               "Yu Gothic", "Meiryo", "Hiragino Sans"]:
        if _n in _fonts:
            matplotlib.rcParams["font.family"] = _n
            break
    else:
        print("注意: 日本語フォントが見つかりません(グラフの日本語が四角になります)")
matplotlib.rcParams["axes.unicode_minus"] = False

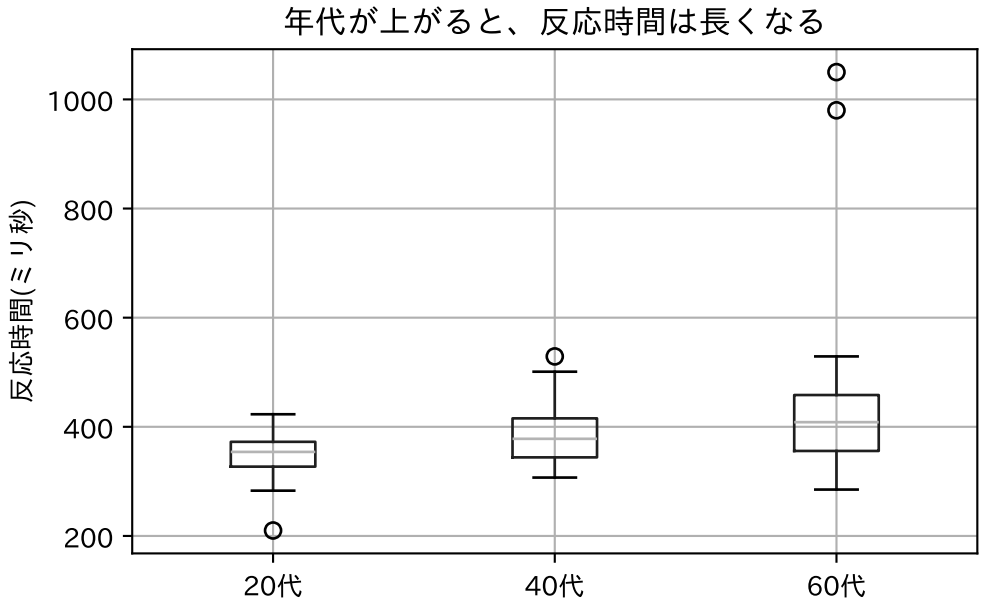
BASE = Path.cwd().parent  # この本では teacher フォルダの1つ上がプロジェクト直下
df = pd.read_csv(BASE / "data" / "test_psych.csv")

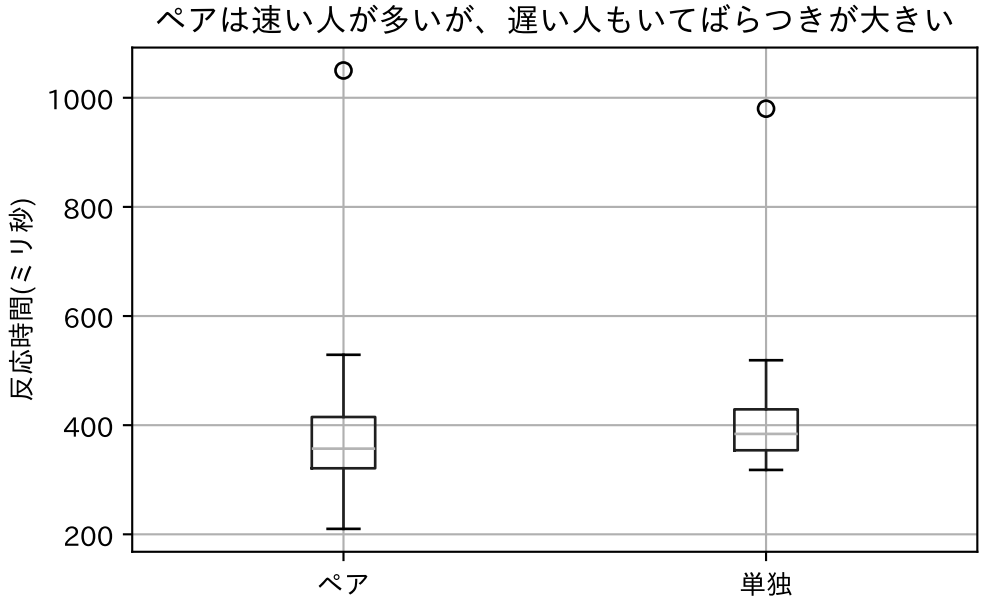
# 作例1: 年代と反応時間(分布で比べる)
df.boxplot(column="反応時間", by="年代")
plt.title("年代が上がると、反応時間は長くなる")
plt.suptitle("")
plt.xlabel("")
plt.ylabel("反応時間(ミリ秒)")
plt.show()

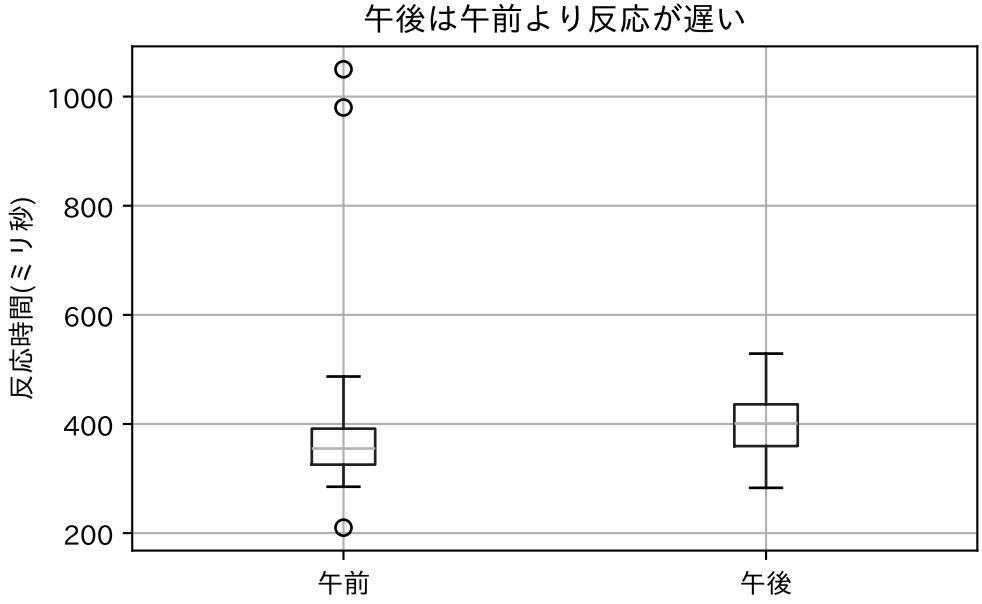
# 作例2: 条件の比較(速さとばらつきの両方)
df.boxplot(column="反応時間", by="条件")
```

```
plt.title("ペアは速い人が多いが､遅い人もいてばらつきが大きい")
plt.suptitle("")
plt.xlabel("")
plt.ylabel("反応時間(ミリ秒)")
plt.show()

# 作例3: 時間帯の比較
df.boxplot(column="反応時間", by="時間帯")
plt.title("午後は午前より反応が遅い")
plt.suptitle("")
plt.xlabel("")
plt.ylabel("反応時間(ミリ秒)")
plt.show()
```




ペアは速い人が多いが、遅い人もいてばらつきが大きい
反応時間(ミリ秒)
1000
800
600
400
200
ペア
単独


午後は午前より反応が遅い
反応時間(ミリ秒)
1000
800
600
400
200
午前
午後

第8コマテスト実施ガイド（講師用）

課題

配布データ（`data/test_psych.csv`：ある注意課題の実験に参加した120名の記録）を眺めて、気づきを**1つ**挙げ、それを「グラフだけで納得させる」形で示す。提出物：①気づき（1文） ②その気づきを納得させるグラフ（タイトル＝主張） ③使ったプログラム。比べる場合は、平均だけでなく分布の格差（中心・広がり・重なり）が見える形を求める。

データに埋め込まれたパターン（採点の目安。受験者はこのうち**1つ**を深める）

1. 年代が上がると反応時間が長い（中央値：20代 約354 → 40代 約378 → 60代約409ミリ秒）
2. ペア条件は単独より速いが、ばらつきが大きい（中央値 357 vs 384、標準偏差 約110 vs 約91）
3. 午後は午前より反応時間が長い（平均 約403 vs 約381ミリ秒）

- おまけ要素：極端に遅い外れ値が2名（980、1050ミリ秒）／反応時間に欠けた値が2件

模範解答コード：`code/answers/session8_answers.py`（上記パターンの作例。比較は分布で示す形）

評価の観点（目安：各**5**点、計**20**点）

- 気づきの正しさ（5）：データの姿に合っているか。埋め込みパターンのいずれか1つを的確に捉えていれば満点相当
- 表とグラフの選択（5）：気づきに合った集計（groupby等）とグラフの形を選べているか。比較が分布の格差で示せていれば加点
- 納得させる工夫（5）：タイトル＝主張、比べる相手を同じ図に、軸は0から、強調色や注釈
- 再現性（5）：プログラムが手元でそのまま再実行できるか

実施上の注意

- 検定などの統計手法は不要と明示する（第1コマの約束どおり）
- 制限時間70分。残り10分で提出前チェックリスト（スライド）を自己確認させる
- データは data フォルダに含まれ、受講者も事前にファイル自体は持っている。課題スターター（`code/session8.py`）は当日に開いてもらう